



TÜBİTAK
MAM

Sensör ve Sistemler Araştırma Grubu

HAVALİMANI ORTAMINDA GERÇEK ZAMANLI ÇEVRESEL SES
SINIFLANDIRMA SİSTEMİ GELİŞTİRME RAPORU

Fatih ADIN

Danışman: Dr. Öğr. Üyesi Aydın Özcan

İSTANBUL, 2026

1. Giriş

Bu proje kapsamında havalimanı çevresinde oluşan çevresel seslerin gerçek zamanlı olarak analiz edilmesi ve sınıflandırılması amacıyla yapay zekâ tabanlı bir ses analiz sistemi geliştirilmiştir. Sistemin temel amacı, farklı noktalara yerleştirilen mikrofonlardan alınan sürekli ses akışını analiz ederek duyulan sesin hangi kategoriye ait olduğunu otomatik olarak belirlemektir. Proje yalnızca bir makine öğrenmesi modeli geliştirmeyi değil, aynı zamanda gerçek zamanlı çalışan bir mühendislik sistemi oluşturmayı hedeflemiştir. Bu nedenle çalışma süreci boyunca veri işleme, canlı ses akışı yönetimi, çok iş parçacıklı mimari, model eğitimi, hata analizi, aktif öğrenme ve kullanıcı arayüzü geliştirme gibi birçok farklı mühendislik problemi birlikte ele alınmıştır.

Sistem beş farklı çevresel ses sınıfı üzerinde çalışmaktadır:

- AIRCRAFT
- AMBIENT
- SPEECH
- TRAFFIC
- WIND

Başlangıç aşamasında temel hedef CNN tabanlı model ile yüksek doğruluk elde etmektir. Ancak ilerleyen süreçte yalnızca laboratuvar ortamında yüksek doğruluk elde etmenin yeterli olmadığı, modelin gerçek dünya koşullarında da kararlı çalışabilmesi gerektiği görülmüştür. Bu nedenle proje ilerledikçe veri çeşitliliği, domain shift problemi ve transfer learning yaklaşımları çalışmanın merkezine yerleşmiştir.

2. Veri Seti ve Veri Hazırlama Süreci

Projede birden fazla veri kaynağı birlikte kullanılmıştır. AIRCRAFT sınıfı için uçak motoru ve kalkış/iniş seslerini içeren özel kayıtlar kullanılmıştır. SPEECH, TRAFFIC ve WIND sınıfları için ESC-50 veri setinden ilgili kategoriler seçilmiştir. AMBIENT sınıfı ise doğrudan havalimanı çevresinde alınan uzun süreli ortam kayıtlarından üretilmiştir.

Veri hazırlama süreci projedeki en kritik aşamalardan biri olmuştur. Özellikle çevresel seslerin çok değişken yapıda olması nedeniyle veri seti temizliği doğrudan model performansını etkileyen bir faktör haline gelmiştir. AMBIENT sınıfı oluşturulurken uzun süreli kayıtlar küçük segmentlere bölünmüş ve enerji tabanlı filtreleme uygulanmıştır. Belirlenen eşik değerinin altında kalan düşük enerjili parçalar veri setine dahil edilmemiştir.

Son durumda veri dağılımı aşağıdaki hale gelmiştir:

Sınıf Örnek Sayısı

AIRCRAFT 1975

AMBIENT 322

WIND 160

SPEECH 160

TRAFFIC 160

Bu dağılım incelendiğinde AIRCRAFT sınıfının diğer sınıflara göre ciddi biçimde fazla örnek içerdiği görülmektedir. Bu durum sınıf dengesizliği problemi oluşturmuş ve eğitim sırasında özel yöntemler uygulanmasını gerektirmiştir.

3. Ses İşleme ve Özellik Çıkarımı

Sistem tüm ses kayıtlarını 22050 Hz örnekleme hızında işlemektedir. Bu nedenle beş saniyelik bir ses kaydı yaklaşık 110250 örnekten oluşmaktadır. Ancak ham ses sinyali doğrudan modele verilmemiştir çünkü zaman domenindeki örnekler sınıflandırma için yeterli seviyede anlamlı örüntü içermemektedir. Sesin ayırt edici bilgisi frekans domeninde bulunduğu için öncelikle frekans analizi uygulanmıştır.

Bu amaçla FFT (Fast Fourier Transform) yöntemi kullanılmıştır. FFT sayesinde ses sinyali frekans bileşenlerine ayrılmıştır. Yapılan analizlerde:

- uçak seslerinin düşük frekans bölgelerinde yoğun enerji içerdiği,
- konuşmanın orta frekans aralıklarında bulunduğu,
- rüzgar seslerinin geniş spektruma yayıldığı

gözlemlenmiştir.

CNN ve EfficientNet modellerinde Mel spektrogram yaklaşımı kullanılmıştır. Bu yöntemde ses, zaman-frekans düzleminde iki boyutlu bir yapıya dönüştürülmektedir. Böylece ses verisi görüntü gibi işlenebilmektedir. Mel ölçeğinin kullanılmasının temel nedeni insan kulağının frekanslara doğrusal tepki vermemesidir. FFT sonrası elde edilen frekans enerjileri Mel filtre bankalarından geçirilmiş, ardından logaritmik ölçekte desibel dönüşümü uygulanmıştır. Sonuç olarak 128 bantlı Mel spektrogram görüntüleri elde edilmiştir.

Klasik makine öğrenmesi yaklaşımında ise el yapımı özellikler kullanılmıştır. Toplam 264 boyutlu bir özellik vektörü oluşturulmuştur. Bu yapı içerisinde:

- MFCC özellikleri,

- chroma bileşenleri,
- spectral özellikler,
- ZCR ve RMS enerji değerleri

yer almaktadır.

Özellikle MFCC bileşenleri konuşma ve motor sesi ayırımında yüksek başarı sağlamıştır. Bu aşamada kritik noktalardan biri eğitim ve gerçek zamanlı inference tarafında kullanılan özellik çıkarım parametrelerinin birebir aynı tutulması olmuştur. Parametrelerde oluşabilecek küçük farklılıkların bile model davranışını bozduğu gözlemlenmiştir.

4. Model Geliştirme Süreci

Proje kapsamında üç farklı model yaklaşımı değerlendirilmiştir:

1. Support Vector Machine (SVM)
2. Convolutional Neural Network (CNN)
3. EfficientNet-B0 tabanlı transfer learning modeli

İlk aşamada SVM modeli geliştirilmiştir. El yapımı 264 boyutlu özellik vektörü kullanılarak eğitilen model oldukça stabil sonuçlar vermiştir. Özellikle veri miktarının sınırlı olduğu durumlarda SVM modelinin güçlü ayırım başarısı gösterdiği gözlemlenmiştir.

SVM modelinin sınıf bazlı performansı aşağıdaki gibidir:

Sınıf	F1 Skoru
-------	----------

AIRCRAFT	0.965
----------	-------

AMBIENT	0.969
---------	-------

SPEECH	0.960
--------	-------

TRAFFIC	0.791
---------	-------

Macro F1	0.897
----------	-------

Bu sonuçlar klasik makine öğrenmesi yaklaşımının kontrollü veri setlerinde oldukça başarılı çalıştığını göstermiştir. Ancak model doğrudan ham veri örüntülerini öğrenemediği için uzun vadede ölçeklenebilir bir çözüm olarak değerlendirilmemiştir.

CNN modeli geliştirilirken Mel spektrogram görüntüleri doğrudan giriş olarak kullanılmıştır. Ağ yapısı frekans kenarlarını, spektral dokuları ve daha karmaşık ses örüntülerini öğrenebilecek şekilde tasarlanmıştır. Eğitim sürecinde learning rate, batch size ve class weight parametreleri üzerinde çok sayıda optimizasyon yapılmıştır.

Kritik eğitim parametreleri şu şekilde belirlenmiştir:

SR = 22050

N_MELS = 128

N_FFT = 2048

HOP_FFT = 512

DURATION = 5.0

EPOCHS = 50

BATCH_SIZE = 32

LR = 1e-3

WEIGHT_DECAY = 1e-4

CNN modeli iç doğrulama testlerinde yaklaşık 0.856 Macro F1 skoruna ulaşmıştır. Ancak dış veri setlerinde ciddi performans kaybı yaşanmıştır. Dış testlerde F1 skorunun yaklaşık 0.204 seviyesine düşmesi modelin gerçek dünya koşullarında başarısız olduğunu göstermiştir.

5. Domain Shift Problemi

Projenin en kritik teknik problemi domain shift olmuştur. CNN modeli eğitim verisi üzerinde oldukça başarılı görünmesine rağmen farklı kaynaklardan gelen çevresel seslerde başarısız olmuştur. Özellikle negatif örneklerin büyük bölümünü AIRCRAFT olarak etiketlediği görülmüştür.

Yapılan analizlerde problemin temel nedenleri şunlar olarak belirlenmiştir:

- AMBIENT sınıfının çok sınırlı kayıt kaynaklarından üretilmesi,
- veri çeşitliliğinin düşük olması,
- çevresel seslerin gerçek dünya varyasyonunu temsil edememesi,
- modelin belirli kayıt örüntülerini ezberlemesi

olmuştur.

Modelin “çevresel ses” kavramını genel bir yapı olarak öğrenmek yerine yalnızca belirli kayıt karakteristiklerini öğrendiği gözlemlenmiştir. Bu nedenle farklı ortamdaki gelen yeni kayıtlar modele tamamen yabancı görünmüştür.

Bu problemi çözmek amacıyla transfer learning yaklaşımına geçilmiş ve EfficientNet-B0 modeli kullanılmıştır.

6. EfficientNet ve Transfer Learning Yaklaşımı

EfficientNet-B0 modeli daha önce milyonlarca görüntü üzerinde eğitilmiş bir ağ olduğu için güçlü özellik çıkarım yeteneğine sahiptir. Proje kapsamında modelin son katmanı değiştirilmiş ve çevresel ses spektrogramları üzerinde fine-tune işlemi uygulanmıştır.

Transfer learning yaklaşımı sayesinde model:

- kenar yapıları,
- doku örüntüleri,
- spektral şekiller,
- frekans dağılımları

gibi genel temsilleri daha güçlü öğrenebilmiştir.

EfficientNet modelinin sonuçları şu şekilde elde edilmiştir:

Değerlendirme Sonuç

İç Test F1 0.877

Dış Test F1 0.709

Aircraft Recall 0.972

Bu sonuçlar CNN modeline göre çok daha güçlü genelleme performansı sağlandığını göstermiştir. Özellikle dış veri setindeki başarı artışı transfer learning yaklaşımının projedeki en önemli iyileştirmelerden biri olduğunu ortaya koymuştur.

7. Kritik Hatalar ve Çözüm Süreçleri

Proje boyunca birçok kritik sistem hatasıyla karşılaşmıştır. Bunlardan en önemlisi AMBIENT veri üretim sürecindeki overflow problemi olmuştur. env_audio_processor.py içerisinde segment indeksleri global olarak ilerletildiği için ikinci ve sonraki dosyalardaki segmentler yanlış eşleşmeye başlamıştır. Sonuç olarak binlerce yanlış etiketli örnek eğitim setine dahil edilmiştir.

Bu problem çözülürken:

- her dosya başlangıcında segment indeksleri sıfırlanmış,
- CSV kapsamı dışındaki segmentler tamamen atılmış,
- doğrulanmamış segmentlerin temiz kabul edilmesi engellenmiştir.

Bir diğer kritik problem BatchNorm ve WeightedRandomSampler etkileşimi olmuştur. Veri dengesizliğini çözmek amacıyla kullanılan sampler yapısı batch dağılımını bozmuş ve BatchNorm istatistiklerinin kararsız hale gelmesine neden olmuştur. Validation loss birkaç epoch içerisinde ciddi biçimde yükselmiştir.

Problemin çözümü için:

- WeightedRandomSampler kaldırılmış,
- class weight yaklaşımına geçilmiş,
- eğitim süreci yeniden stabilize edilmiştir.

8. Gerçek Zamanlı Ses İşleme Sistemi

Sistemin en karmaşık mühendislik bileşenlerinden biri gerçek zamanlı ses işleme altyapısı olmuştur. Model beş saniyelik pencere ile çalışmasına rağmen mikrofona sürekli akış halinde gelmektedir. Bu problemi çözmek amacıyla rolling buffer mimarisi geliştirilmiştir.

Sistem şu şekilde çalışmaktadır:

1. Ses küçük bloklar halinde alınır.
2. Buffer içerisindeki eski veri sola kaydırılır.
3. Yeni ses verisi buffer sonuna eklenir.
4. Her saniyede bir son beş saniyelik pencere modele gönderilir.

Bu yapı sayesinde hem düşük gecikme sağlanmış hem de modelin ihtiyaç duyduğu sabit pencere boyutu korunmuştur.

Gerçek zamanlı inference işlemleri yoğun hesaplama gerektirdiği için çok iş parçacıklı mimari kullanılmıştır. GUI işlemleri ana thread üzerinde çalışırken ses işleme ve inference işlemleri ayrı worker thread'lerinde yürütülmüştür. Sounddevice callback fonksiyonları içerisinde ağır işlem yapılmamış, yalnızca queue yapısına veri aktarılmıştır. Bu yaklaşım GUI donmalarını ve ses kayıplarını önlemiştir.

9. DeviceMultiplexer Yapısı

Gerçek zamanlı sistem geliştirilirken aynı fiziksel mikrofonun birden fazla thread tarafından kullanılamaması problemiyle karşılaşmıştır. Bu problemi çözmek amacıyla DeviceMultiplexer yapısı geliştirilmiştir.

Bu sistemde:

- tek fiziksel mikrofon stream'i açılmış,
- gelen veri birden fazla subscriber queue'suna dağıtılmış,
- her worker kendi bağımsız mikrofonu varmış gibi çalıştırılmıştır.

Bu yaklaşım özellikle çoklu test senaryolarında önemli avantaj sağlamıştır.

10. Harita ve Görselleştirme Sistemi

İlk aşamada harita sistemi için folium ve QWebEngineView tabanlı bir yaklaşım denenmiştir. Ancak Leaflet.js bağımlılıklarının yüklenememesi nedeniyle ciddi sorunlar yaşanmıştır. Özellikle CDN erişim problemleri nedeniyle harita bileşenleri düzgün çalışmamıştır.

Bu problem sonrasında contextily ve matplotlib tabanlı yeni bir yaklaşım geliştirilmiştir. OpenStreetMap tile'ları doğrudan PNG olarak alınmış ve matplotlib üzerinden görselleştirilmiştir. Böylece:

- web bağımlılıkları kaldırılmış,
- sistem stabil hale gelmiş,
- platform uyumluluğu artırılmıştır.

11. Annotation ve Active Learning Sistemi

Sistemin uzun vadede gelişebilmesi amacıyla annotation altyapısı geliştirilmiştir. Kullanıcı sistemin yaptığı tahminleri inceleyebilmekte ve yanlış sınıflandırmaları düzeltebilmektedir. Yapılan düzeltmeler CSV formatında kaydedilmektedir.

Kaydedilen bilgiler arasında:

- ses dosyası,
- zaman aralığı,
- orijinal etiket,
- düzeltilmiş etiket,

- kullanıcı notu

bulunmaktadır.

Bu yapı sayesinde modelin yaptığı hatalar yeni eğitim örneklerine dönüştürülebilmektedir. Böylece sistem zamanla kendi hatalarından öğrenebilen active learning tabanlı bir yapıya dönüşmektedir.

12. Sonuç

Bu proje kapsamında yalnızca çevresel ses sınıflandırması yapan bir model değil, aynı zamanda gerçek zamanlı çalışan, canlı veri işleyebilen, kullanıcı geri bildirimi toplayabilen ve yeni verilerle kendisini geliştirebilen bütünlük bir sistem geliştirilmiştir.

Proje süreci boyunca:

- veri mühendisliği,
- model genellemesi,
- transfer learning,
- gerçek zamanlı ses işleme,
- thread yönetimi,
- aktif öğrenme,
- görselleştirme altyapısı

gibi birçok farklı mühendislik problemi çözülmüştür.

Elde edilen sonuçlar transfer learning yaklaşımının düşük veri koşullarında güçlü genelleme avantajı sağladığını göstermiştir. EfficientNet modeli şu an sistem içerisindeki en başarılı çözüm olarak değerlendirilmektedir.

Gelecek çalışmalarda canlı ortamdan otomatik veri toplama, annotation verilerinin doğrudan eğitim pipeline'ına aktarılması ve sürekli fine-tune mekanizmasının kurulması hedeflenmektedir. Özellikle AMBIENT ve WIND sınıflarına ait veri çeşitliliği arttıkça sistemin gerçek havalimanı koşullarında daha kararlı çalışması beklenmektedir.